GOOGLE STUDY JAM PBL · RAG 프로젝트

초등 영어 · 내 문장 고쳐주기 튜터

아이가 말하거나 쓴 영어 문장을, **교과서 규칙을 찾아서** 고쳐 주는 AI 선생님

팀 5인 | 3주 · 2026.9.4 ~ 9.19 | FastAPI + HTML · 교실 GPU 서버

과제: "RAG 시스템을 만들어라" → 우리 답: 초등 영어 문장 고치기 → 5명이 나눠 맡음

왜 이 문제인가? 답은 정해져 있고, 질문만 매번 다르다.

- **답** = 교과서 문법 규칙 100개. 이건 미리 다 적어 둘 수 있다.
- **질문** = 아이가 쓴 문장. 매번 다르고 라벨이 없다.
- 선생님이 하던 "이 문장은 어느 규칙이 틀렸지?" 를 **검색**이 대신한다. 선생님의 일을 대신해 주는 튜터.

데이터 2명
골든 데이터
규칙·FAQ·단어·문장·시험지 만들고 검수

검색 1명
임베딩·색인
무엇을 어떻게 색인할지, 검색 정확도

음성·챗봇 1명
듣기·말하기·챗봇 + 교실 서버
STT·TTS·발음 평가·/ask·GPU 서버 운영

팀장 1명
서비스·화면·고쳐주기·평가
기획, 화면, /fix, 관리자·평가 도구, 통합

아이는 이 다섯 걸음을 돈다

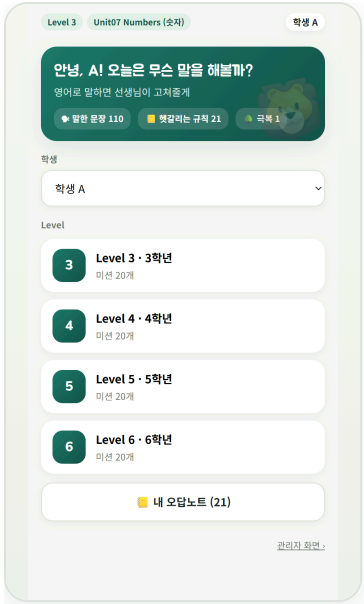
1
듣고 따라 말하기
유닛 단어·문장을 듣고 따라 말하면 점수와 닮은 정도

2
내 문장 말하기 · 쓰기
오늘의 미션에 맞춰 한 문장

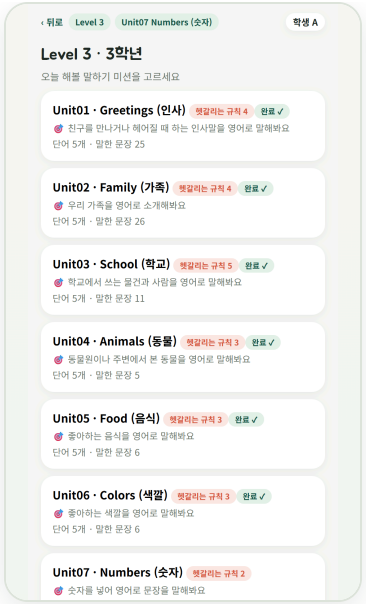
3
고쳐주기 + 이유
어느 규칙인지 찾아서 한 군데만 고치고 쉽게 설명

4
오답노트
틀린 규칙이 쌓이고, 연습 문제로 이어짐

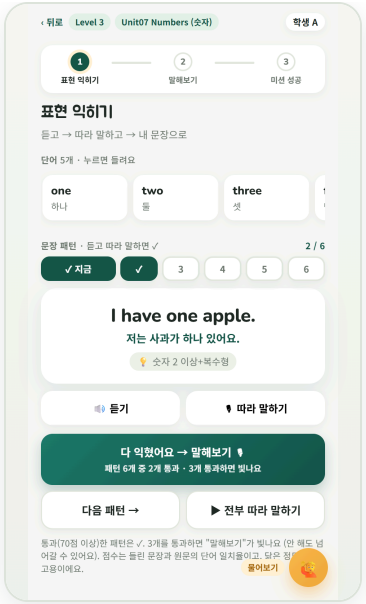
5
더 물어보기
챗봇에게 "왜?" "다른 예문은?"



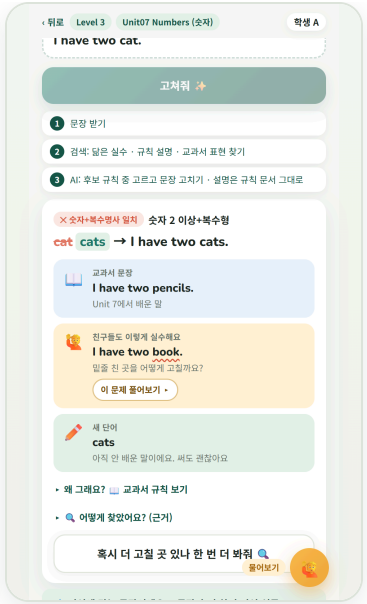
시작 · 학생 고르기



유닛 고르기



1 듣고 따라 말하기



2·3 내 문장 → 고쳐주기

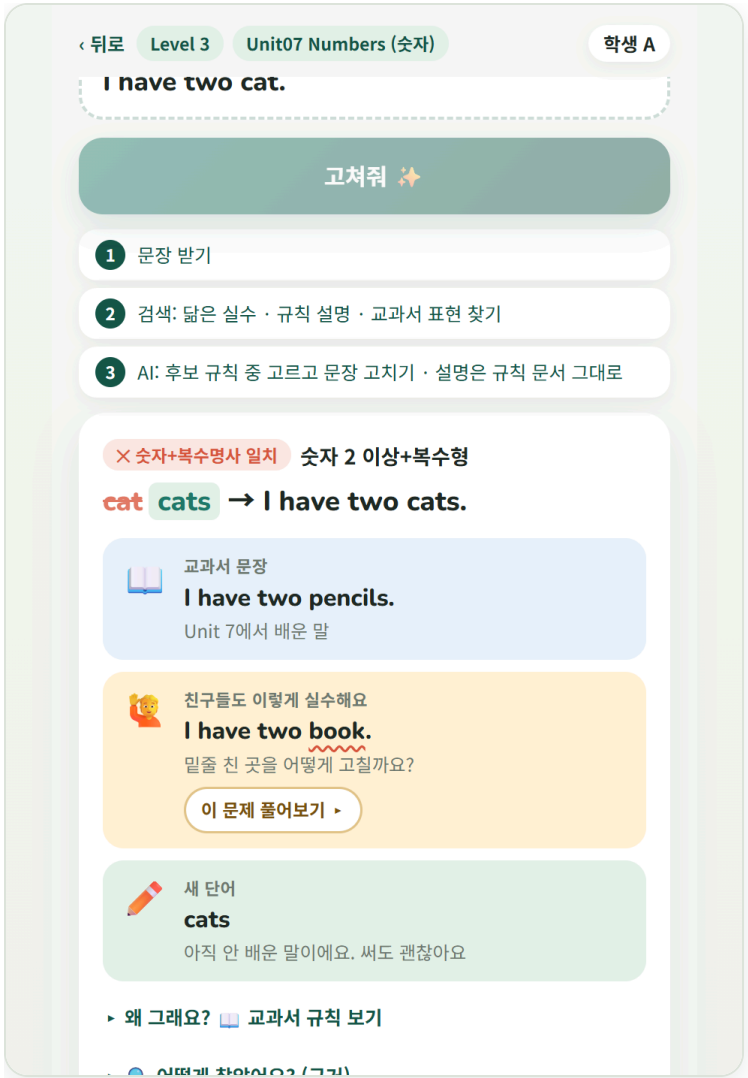


4 오답노트

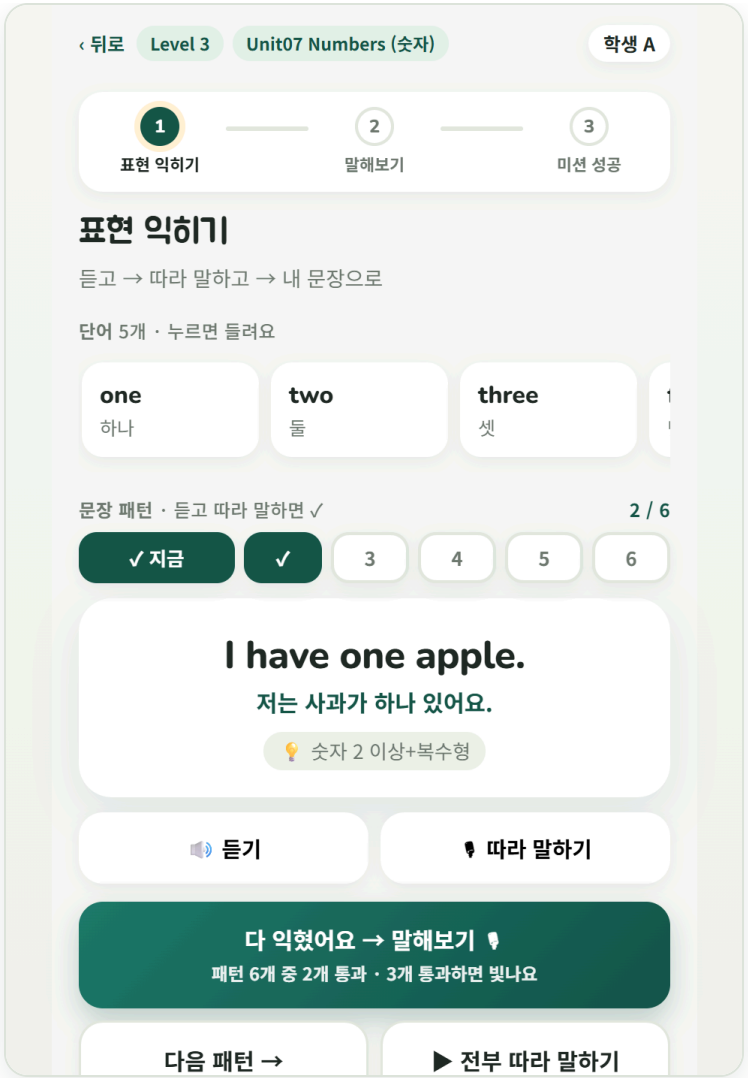


5 더 물어보기

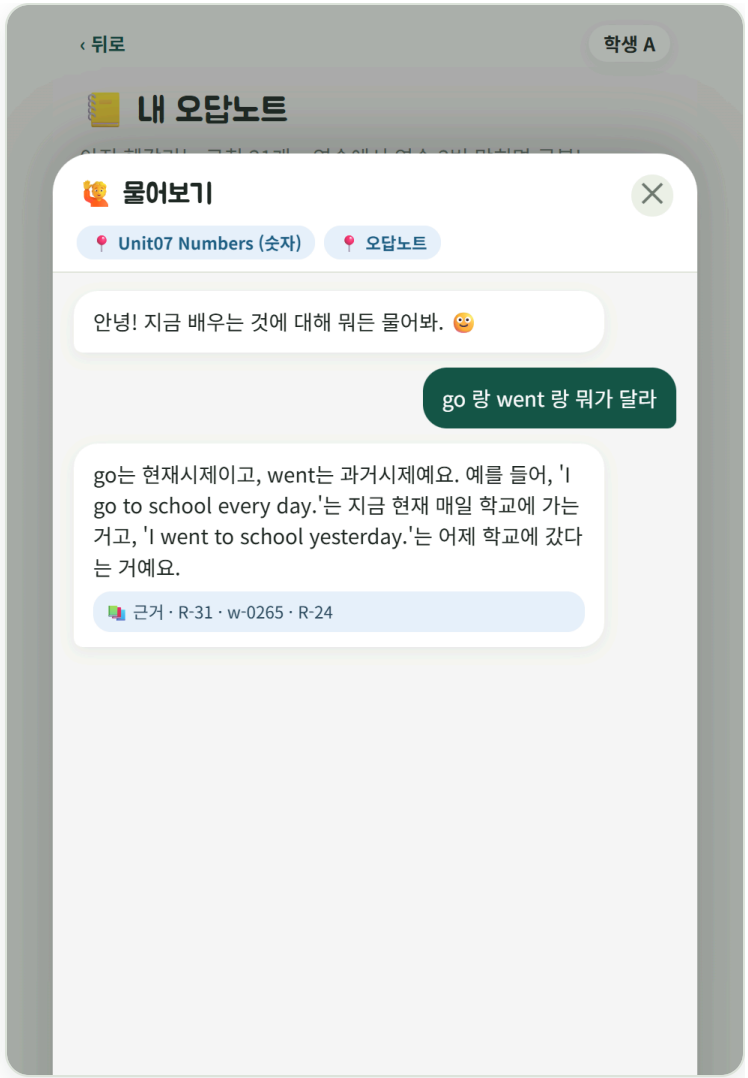
학생이 보는 것 (실제 화면)



고쳐주기: 어느 규칙인지 · cat → cats · 교과서 문장 · 친구들의 실수



표현 익히기: 단어 듣기 → 문장 듣기 → 따라 말하기 → 점수와 🌱



챗봇: "go 랑 went 랑 뭐가 달라" → 답 + 근거 R-31

구조

화면
HTML + JS
표현 익히기 · 고쳐주기 · 오답노트 · 챗봇 · 관리자

서버
FastAPI
담당별 파일 하나씩: tutor · ask · speak · tts · rag

교실 GPU 서버
Ollama 32B · Whisper · 임베딩
답변 모델 · 받아쓰기 · 검색 벡터

데이터
골든 데이터 + 색인
규칙·FAQ·단어·문장, Chroma 색인 5개

기획이 바뀐 자리 네 곳

9/7
단어 4지선다(A안) → 내 문장 고치기(B안). 검색이 진짜 필요한 쪽으로

9/11 · RAG 의 위기
만들어 놓고 보니 규칙 이름을 찾아 주는 검색기였지 RAG 가 아니었다 → 틀린 예문·FAQ·교과서 문장까지 색인해 "우리 규칙으로 답하는" RAG 로

9/16
챗봇을 규칙 기반에서 모델 우선으로

9/17
속도(모델 스왑)와 미션 판정 손보기

문법 규칙
100

자주 묻는 질문
130

단어
400

교과서 문장
475

시험지
360
규칙마다 틀린 문장 3 + 맞는 문장 60 · 고쳐주기는 늘 이걸로 잰다

데이터를 두 번 고쳤다 — 9/15 정비 · 9/16 팩트체크 · 9/17 정정 5건

86.0 → 85.7 시험지 점수, 오차 안

데이터 품질은 올랐지만 점수는 그대로였다. 검색은 이미 맞는 규칙을 찾고 있었다. 남은 실패는 다른 데 있었다.

그 "다른 데"를 시험지가 찾아냈다

R-46 시험 문장 3개, 두 번 고쳐도 계속 ✗

Who homework is this?

모델 답: Who → **Whose** ✓ → 서버가 "철자 실수"로 잘못 걸러 ✗

데이터가 아니라 서버 코드 문제. 한 줄 고쳐서 3문장 통과.

임베딩 모델을 실측으로 골랐다

모델 (n=65, hit@1)	
gemini-embedding-001	**76.9%**
multilingual-e5-base (지금 운영)	**72.3%**
all-MiniLM-L6-v2	**70.8%**
bge-m3	**60.0%**

1위는 gemini 였지만 API 키·한도 없이 돌리려고 교실 GPU 의 e5-base 로 운영.

무엇을 색인했나

- 규칙 **설명문**만 → 정답이 3위 안에 **84.7%**
- 규칙의 **틀린 예문**도 → **93.0%**
- 둘을 합쳐서 → **93.3%**
- + FAQ · 규칙 별칭 · 교과서 문장·단어

아이 문장은 "설명문"보다 "틀린 예문"을 닮는다. 그래서 예문 색인이 효과가 컸다.

검색 없이 규칙 100개 다 줌

71

360문장 중 맞힌 규칙 %

검색으로 후보 8개만

85.7

같은 360문장

맞는 문장을 맞다고

56/60

억지로 고치지 않기

1

철자 먼저

사전으로 schol→school

2

검색

규칙+예문에서 후보 8개

3

모델이 고름

한 군데만 고치고 이유

4

검증기

모델 답이 규칙에 맞는지 10가지 검사

5

재확인

애매하면 한 번 더 묻기

4번 검증기: 고친 단어가 학생 문장에 있는지, "eat → cook" 처럼 뜻을 바꾸지 않았는지 확인해서 아니면 내보내지 않는다. 모델 답을 한 번 걸러 주는 장치.

받아쓰기 시간 (교실 GPU)
0.5초

깨끗한 소리 오류율 (475문장)
0.08%
2,539단어 중 2개

한·영 섞인 말 300문항 — 뜻이 통하게 들음
90.7%
완전 동일 13.7% + 조사·띄어쓰기만 다른 부분 동일 77.0% · 완전 틀림 9.3%

한국어와 영어가 섞인 말을 어떻게 듣나

- 같은 소리를 **한국어로 한 번, 영어로 한 번** 받아쓴다. "엘러펀트가 뭐야" ↔ "elephant …"
- 영어 쪽에만 **학습 단어**가 있으면, 모델이 그 단어만 바꿔서 합친다 → "elephant 가 뭐야"
- **합치기 전**: 바꿀 학습 단어가 없으면 합치지 않는다(전엔 100문항 중 30개+ 가 통째로 영어 번역) · 무음에서 나오는 "Thank you" 환각은 지운다 (무음 5번 중 5번 재현)
- **합친 뒤 검사 2개**: ① 단어 수가 늘었으면 거절 — "elephant" 한 마디가 "elephant 는 뭐예요?"로 불어난 것 ② 한글이 30% 밑으로 줄었으면 거절 — 통째 번역. 하나라도 걸리면 한국어로 받아쓴 원래 결과를 그대로 쓴다
- 이 검사로 잡은 버그 **0/5 → 5/5** (같은 사례 3회 재검증)

선생님 목소리: Gemini → Piper 로컬

- Gemini TTS 는 하루 **10회** 한도 → 로컬 합성으로 **무제한**, 키·인터넷 없이
- 한 번 만든 소리는 저장. 문장 475개 전부 미리 합성

평가는 두 축

- **맞았나**: 들린 말과 원문의 단어 일치율 (70점 통과)
- **닮았나**: 소리 특징(Whisper 인코더)을 DTW 로 겹쳐 봄 → 🌱 🌿 🌳 3단계만

실제 목소리 16개로 기준 잡기

잘 읽은 8개 · 잘못 읽은 8개가 겹치지 않고 갈림

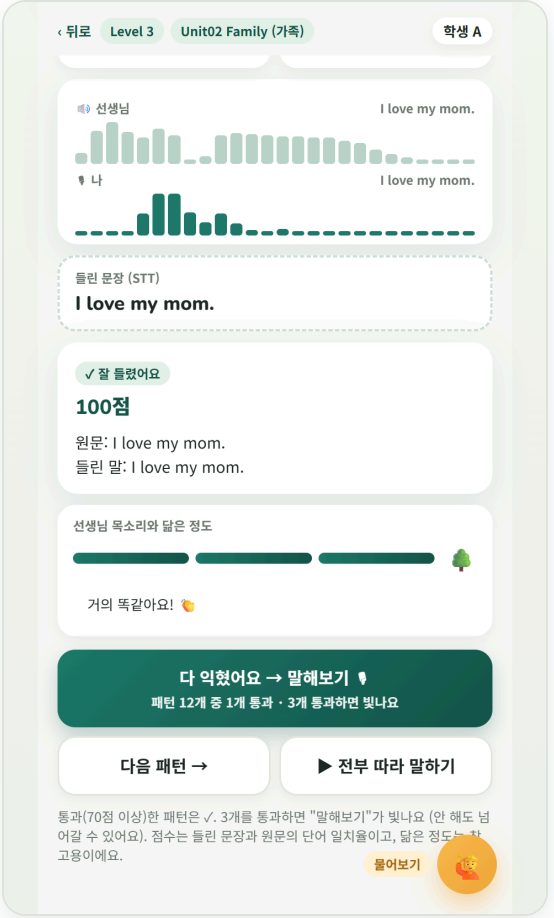
선생님 소리와 얼마나 다른지 잰 값이 잘 읽은 쪽은 21~26, 잘못 읽은 쪽은 28~33. 그 사이를 기준선으로 점수 공식을 만듦

따라 말하기 응답

10초 → 1.6초

① 언어를 영어로 고정해 로컬 언어 감지 5초 제거 ② 발음 비교 스레드를 1개 → CPU 코어 절반으로

정직한 한계: "살짝 틀린 발음"은 못 가른다. 그래서 숫자 대신 3단계.



따라 말하기 결과: 선생님·나 파형 · 100점 · 🌳 거의 똑같아요

규칙으로 답을 정하다가, 모델에게 맡기고 코드는 검사만

질문	전 (규칙 기반)	후 (모델 우선)
영어로 숫자 10까지 알려줘	"Unit12 에서 배워요. 선생님께 물어볼까?"	one, two, … ten (출처 Unit07 단어)
가족 구성원을 영어로	"family 는 가족이라는 뜻이에요"	mom·dad·sister·brother + 예문 (Unit02)
go 랑 went 랑 뭐가 달라	교과서 밖이라고 함	현재/과거 설명 (출처 R-31 과거시제)
오늘 저녁 메뉴가 뭐야	"morning 은 아침이라는 뜻"	"영어 공부 질문이 아니라서…"

"교과서 안/밖" 판정 정확도 (100문항)

93% → 99%

모델 자기보고 → 코드가 답 내용을 교과서와 대조

회귀 시험 통과

36/36 · 29/29

FAQ 39/39 유지 · 로그 50턴 중 30턴 개선

질문을 가로채던 판단 코드 걷어내기

1,548 → 654줄

"이 단어면 이 답" 식으로 질문을 가로채던 코드. 실제 로그에서 도움이 된 건 24번 중 1번뿐 → 지우고 모델에 맡김

"고치기 전에 재고, 고친 뒤 다시 잰다"

실험실 화면

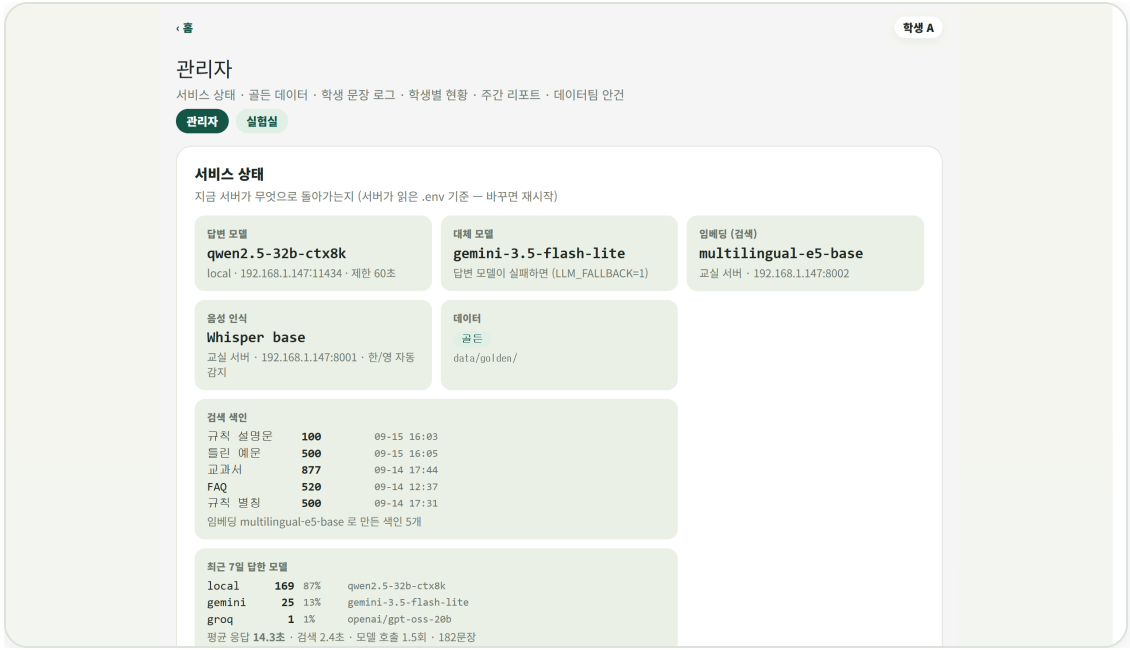
- 검색 정확도 (hit@1·3)
- 튜터 정확도 — 360문장 절제 실험 버튼
- STT 정확도 — WER
- 교과서 검색 시험 · 생성 점검

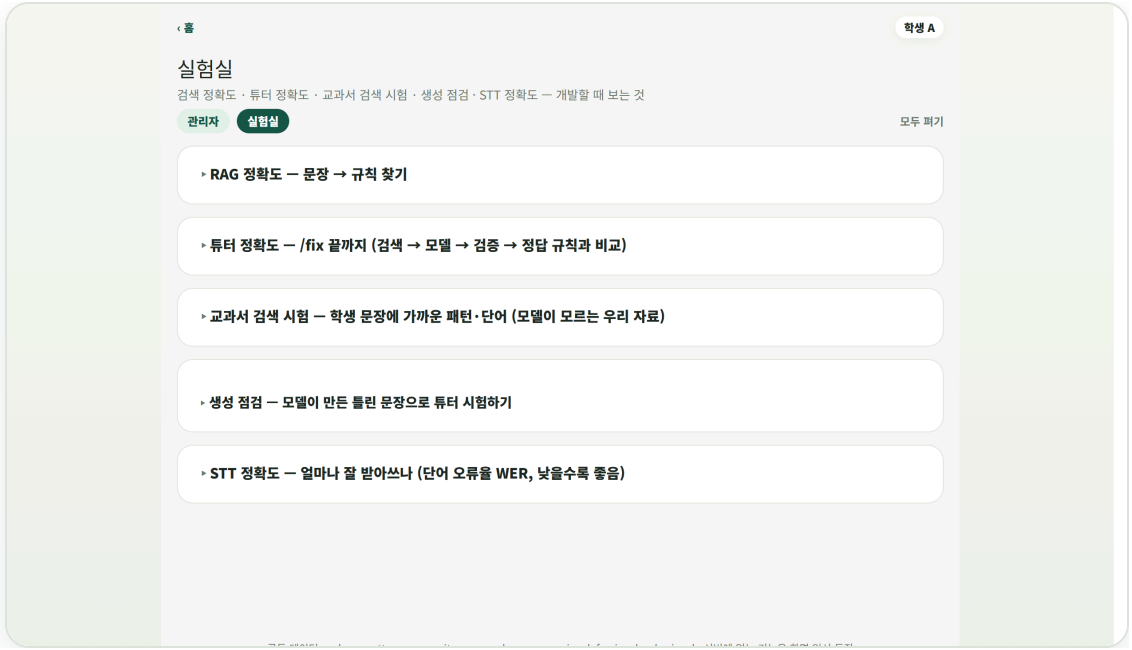
관리자 화면

- 서비스 상태 (모델·서버·색인 오래됨)
- 학생별 현황 · 문장 로그
- 주간 리포트 (BigQuery, 없으면 파일 집계)

스크립트 4개

- eval_fix — 고쳐주기
- eval_stt — 받아쓰기
- ask_regression — 챗봇
- exp_ask_check — 문장 판정





검색이 정답을 3위 안에
93.3%

고쳐주기 규칙 적중
85.7%
검색 없으면 71

맞는 문장 유지
56/60

문장 판정 (챗봇)
93%

받아쓰기 오류율 · 한·영 섞인 말
0.08% · 90.7%
깨끗한 영어 475문장 · 섞인 말 300문항 뜻 통함

챗봇 교과서 안/밖 판정
93% → 99%
FAQ 밖 질문 30/50 → 답변

고쳐주기 응답
5.5초
재확인 붙으면 6~11초

따라 말하기 응답
1.6초
처음엔 10초

아직 비어 있는 칸: 실제 목소리의 🌱 🌿 🌳 분포 — 발음 평가는 정답·오답 16개로 공식을 잡은 것까지가 실측.

1 · 데이터를 고쳤는데 점수가 그대로

규칙·예문을 두 번 정비했는데 86.0 → 85.7, 오차 안.

검색은 이미 맞는 규칙을 찾고 있었다. 남은 실패는 모델의 선택과 시험지의 모호함이었다.

2 · 작은 모델로 바꿨더니 더 느려짐

7B 로 바꿔도 8초. 알고 보니 GPU 에 모델이 하나만 올라가서 팀원과 다른 모델을 쓰면 호출마다 7~8초 갈아 끼움.

팀 모델 통일로 해결. 8초의 정체는 "로딩"이었다.

3 · 답을 짧게 쓰라고 했더니 틀린 걸 맞다고 함

출력 JSON 을 줄이니 규칙 적중 257 → 180.

"짧게"를 모델이 "맞다고 하면 짧다"로 읽었다. 폐기하고 원복.

음성 쪽 하나 더: 하루에 Whisper → MFCC → 다시 Whisper, 세 번 뒤집은 발음 평가.

답이 정해진 도메인에서, AI 가 아는 척하지 않고 교과서에서 찾은 것만 말하게 만든 3주.

- 발음 비교를 교실 GPU 로 옮기기
- 챗봇의 미션·판정에서 모델 의존 줄이기
- 단어장 보강 (chicken·food 같은 흔한 단어)